

به نام خدا



گزارش تمرین اول

موضوع:

غذاهای محلی گروه ۴

شماره گروه: ۱۱

اعضا گروه:

مریم برزو ۴۰۳۲۰۶۶۲۷

یاسمین توکلی ۴۰۲۲۱۲۴۵۲

الهه فرشادفر ۴۰۳۳۰۱۸۷۲

۱- مقدمه

این پروژه با هدف جمع‌آوری و ساختاردهی داده‌های مربوط به غذاهای محلی استان‌های ایلام، لرستان، کرمانشاه، همدان، مرکزی و خوزستان انجام شد. با توجه به اهمیت داده‌های بومی در توسعه مدل‌های پردازش زبان طبیعی، تلاش شد اطلاعاتی کامل، دقیق و قابل‌استفاده از غذاهای سنتی این مناطق گردآوری شود. فرآیند کار شامل استخراج داده از منابع معتبر، تمیزسازی، استانداردسازی اطلاعات و آماده‌سازی نهایی در قالب JSON بود، به گونه‌ای که داده‌ها قابلیت استفاده مستقیم در پروژه‌های تحلیلی یا آموزشی را داشته باشند.

۲- روش گردآوری داده‌ها

برای جمع‌آوری داده‌ها، سه وب‌سایت اصلی **کوک‌پد**، **جانبو و روستانت** به عنوان منابع انتخاب شدند. به دلیل ساختار متفاوت این سایت‌ها و وجود محتوای بارگذاری‌شونده، از ترکیبی از ابزارهای **Selenium (Dynamic)** برای بارگذاری صفحات و **BeautifulSoup (Static)** برای استخراج اطلاعات از کد HTML استفاده شد. اطلاعات استخراج‌شده شامل نام غذا، مواد اولیه همراه با مقدار و واحد اندازه‌گیری، دستور تهیه و محل جغرافیایی هر غذا بود. داده‌های خام پس از استخراج، بر اساس ساختار مشخص شده در تمرین، در قالب JSON سازماندهی شدند تا برای مراحل بعدی مانند برچسب‌گذاری و تحلیل آماده باشند.

۳- پردازش داده‌ها

در ابتدا لیست کاملی از غذاهای استان‌های گروه ۴ بدست آوردیم که آن را در لینک مشاهده می‌کنید. سپس لینک هر یک از این غذاها را در یکی از سایت‌های نام برده پیدا کردیم. در ادامه با توجه به ساختار صفحات و آنچه در ورکشاپ اول یادگرفتیم، اطلاعات را از صفحات وب استخراج کردیم. هدف اصلی این است که اطلاعات مربوط به دستورهای غذایی مانند مواد لازم، طرز تهیه، نوع غذا، زمان مناسب برای مصرف (مثلاً ناهار یا شام)، و مکان‌های مرتبط (شهر و استان) استخراج شود. در ادامه بخش‌های مختلف کد را بررسی می‌کنیم.

۱. نصب پکیج‌های مورد نیاز

```
!pip install requests beautifulsoup4 selenium tqdm
```

Executed at 2025.04.26 01:06:01 in 6s 43ms

```
!pip install selenium webdriver-manager
```

Executed at 2025.04.26 01:06:09 in 2s 938ms

۲. موقعیت جغرافیایی

در این بخش، **city_location_map** تعریف شده که مختصات جغرافیایی (عرض و طول جغرافیایی) شهر و استان‌های مربوطه را ذخیره می‌کند که برای استخراج مکان‌های مرتبط با دستورهای غذایی استفاده می‌شود. همچنین از **suffix_location_map** برای تشخیص استان‌ها و شهرها از بخش‌های انتهایی URL و نام غذاها استفاده می‌کند.

۳. تشخیص نوع غذا

تابع **detect_meal_type** وظیفه دارد تا نوع غذا (مثلاً غذای اصلی گوشتی، دسر، پیش‌غذا، و غیره) را بر اساس عنوان و مواد اولیه دستور غذا شناسایی کند. این تابع بر اساس کلمات خاص موجود در عنوان یا مواد اولیه غذا، نوع غذا را تشخیص می‌دهد.

```
def detect_meal_type(title, ingredients_text):
    title_lower = title.lower()
    ingredients_lower = ingredients_text.lower() if ingredients_text else ""

    if any(w in title_lower for w in ["تېگوفت", "حكر", "خورفت", "خورش", "كباب", "كوفته", "دليعه", "كنند", "قايي"]):
        return ["غذای اصلی گوشتی"]
    if any(w in title_lower for w in ["پلو", "پزنج", "پرنجی", "چلو"]):
        return ["غذای اصلی پرنجی"]
    if any(w in title_lower for w in ["آش", "سوپ", "حليم", "افکنه"]):
        return ["آش و سوپ"]
    if any(w in title_lower for w in ["خوراک", "یورایی", "کوکو", "املت"]):
        if "کوفت" in ingredients_lower:
            return ["غذای اصلی گوشتی"]
        return ["غذای اصلی گیاهی"]
    if any(w in title_lower for w in ["فیرینی", "حلوا", "کیک", "بستنی", "دسر", "قله", "سهبلیه"]):
        return ["دسر"]
    if any(w in title_lower for w in ["نان", "ساجی", "لواش", "تافتون"]):
        return ["نان و شیرینی"]
    if any(w in title_lower for w in ["سالاد", "ترشی", "ماست"]):
        return ["پیش غذا و مکمل"]
    if "کوفت" in ingredients_lower:
        return ["غذای اصلی گوشتی"]
    if "پزنج" in ingredients_lower:
        return ["غذای اصلی پرنجی"]
    if "حكر" in ingredients_lower or "عمل" in ingredients_lower:
        return ["دسر"]
    return ["-"]
```

تابع `detect_occasion` به تشخیص زمان مصرف غذا (صبحانه، ناهار، شام، عصرانه، و غیره) بر اساس کلمات موجود در عنوان دستور غذا می‌پردازد.

```
def detect_occasion(title, meal_type, ingredients=None, tags=None, season=None, time_of_day=None, is_weekend=False):
    title_lower = title.lower()
    ingredients_lower = ingredients.lower() if ingredients else ""
    tags_lower = [tag.lower() for tag in tags] if tags else []

    MAIN_OCCASIONS = {
        "صبحانه": ["صبحانه", "ناشتا", "کنک", "پانچ", "حلیم", "املت", "تیغیرو", "پنیر"],
        "ناهار": ["ناهار", "چاقیت", "ظهر", "هلو", "برنج", "چلو", "جورفت", "آبگوشت"],
        "شام": ["شام", "فیان", "کیاب", "آبگوشت", "دیزی", "کیک", "دسر", "قیرینی", "چای", "مصرانه"],
        "میخری": ["رمضان", "میخری"],
        "افطاری": ["افطاری"]
    }

    primary_occasion = None

    if any(kw in title_lower for kw in MAIN_OCCASIONS["میخری"]):
        return "میخری"

    if any(kw in title_lower for kw in MAIN_OCCASIONS["افطاری"]):
        return "افطاری"

    for occasion, keywords in MAIN_OCCASIONS.items():
        if any(kw in title_lower for kw in keywords):
            primary_occasion = occasion
            break

    if not primary_occasion:
        if time_of_day == "صبح":
            return "صبحانه"
        if time_of_day == "مصر":
            return "مصرانه"
        return "شام" if not is_weekend else "ناهار"

    return primary_occasion
```

۴. مواد اولیه و دستور تهیه

تابع `parse_ingredient_line` برای تجزیه و تحلیل خطوط مواد اولیه طراحی شده است. این تابع به طور خاص برای شناسایی مواد اولیه و مقادیر آنها در دستورات پخت استفاده می‌شود. تابع با استفاده از عبارات منظم (Regular Expressions) می‌تواند انواع مختلف واحدهای اندازه‌گیری (مثل قاشق چایخوری، گرم، لیتر، و غیره) را شناسایی کرده و مقادیر آن‌ها را استخراج کند. باید توجه کرد که در زبان فارسی افراد مختلف فرم نوشتار متفاوتی دارند از این رو باید فرم‌های نوشتاری مختلف را لحاظ کنیم. برای مثال: قاشق غذاخوری به صورت‌های "قاشق غذاخوری"، "قاشق غذا خوری"، "ق غذاخوری"، "ق غذا خوری" و "ق غ" نوشته می‌شوند. علاوه بر این‌ها عدم رعایت فاصله‌ها هنگام نوشتار

میزان نیز یکی از مشکلات بود که در این تابع به آن پرداخته شده است. در نتیجه این تابع قادر است مواد اولیه را از جمله در قالب‌های مختلف شناسایی کند، حتی زمانی که ممکن است نام مواد اولیه با اعداد یا سایر علائم خاص همراه باشد. به عنوان مثال: شناسایی مقادیر کسری مانند "۱/۲ قاشق چایخوری"، شناسایی واحدهای اندازه‌گیری مختلف مانند "گرم"، "قاشق غذاخوری"، "لیتر" و غیره و استخراج مواد اولیه حتی زمانی که متن شامل توضیحات اضافی باشد. تابع `split_instructions` برای تقسیم دستورالعمل‌های تهیه غذا به بخش‌های کوچک‌تر استفاده می‌شود. این تابع به طور خودکار دستورالعمل‌ها را به مراحل مختلف تقسیم می‌کند تا هر مرحله به طور جداگانه استخراج و تحلیل شود. هدف این تابع این است که دستورات طولانی و پیچیده به اجزای قابل فهم‌تری تقسیم شوند، به طوری که هر مرحله به طور مجزا قابل پردازش و انجام باشد. به طور مثال: تقسیم دستورالعمل‌ها به قسمت‌هایی مانند "آماده‌سازی مواد"، "پخت غذا" و "تزیین"، شناسایی مراحل خاص که ممکن است به زمان یا دما وابسته باشند و جداسازی دستورات به گونه‌ای که بتوان آن‌ها را به صورت مرحله به مرحله دنبال کرد.

تابع `extract_cookpad_recipe` وظیفه دارد داده‌های دستور غذا را از قالب JSON استخراج کرده و به یک فرمت ساختاریافته تبدیل کند. این تابع علاوه بر استخراج اطلاعات معمولی مثل نام مواد اولیه و مراحل دستور پخت، اطلاعات مربوط به مکان (شهر یا استان) و مواد اولیه را نیز اضافه می‌کند. این فرآیند به ویژه برای اطمینان از ارتباط هر دستور پخت با محل جغرافیایی مناسب آن و استخراج ویژگی‌های مرتبط با مناطق مختلف (مثل سبک غذایی یا ادویه‌های خاص هر منطقه) اهمیت دارد. این تابع شامل موارد زیر است:

- ❖ استخراج داده‌های مربوط به مواد اولیه و دستور تهیه از قالب JSON
- ❖ اضافه کردن اطلاعات مکان (استان یا شهر) از URL یا داده‌های متا
- ❖ نرمال‌سازی نام مواد اولیه و واحدهای اندازه‌گیری برای تطابق با استانداردهای مشخص
- ❖ اضافه کردن اطلاعات مفید مانند زمان پخت، نوع غذا، و حتی نوع وعده (صبحانه، نهار، شام) یا مناسبت‌ها (مثل مهمانی‌ها یا مراسم خاص)

۴- برچسب گذاری و کنترل کیفیت داده‌ها

در نهایت خروجی های JSON در لیبل استودیو توسط کد زیر در دو مرحله لیبل گذاری شد:

```
<View>
</ "Text name="source" value="$name">
<"Choices name="answer" toName="source" choice="single" required="true">
  <Choice value="0">Bad</Choice>
  <Choice value="1">Good</Choice>
</Choices>
</View>
```

در این پروژه، خروجی‌های برچسب‌گذاری در قالب JSON ذخیره شده‌اند تا به راحتی در مراحل بعدی پردازش داده‌ها استفاده شوند. لیبل‌ها شامل دو تگ `good` و `bad` می‌شوند. در صورت `null` بودن و یا وجود ایرادات در اطلاعات ذخیره شده، تگ `bad` و در غیر این صورت از تگ `good` استفاده کردیم. این کار توسط دو نفر انجام شد. در ادامه کار داده‌هایی که تگ `bad` گرفته بودند اصلاح شدند و سپس تگ آنها به `good` تغییر وضعیت داده شد.

۵- چالش‌ها و مشکلات

در روند پردازش و استخراج اطلاعات، چالش‌های متعددی به وجود آمد که نیاز به طراحی راهکارهای ویژه برای حل آن‌ها احساس شد. در این بخش مهم‌ترین مشکلات را به طور جامع‌تر بررسی می‌کنیم:

تنوع نوشتار فارسی اعداد:

یکی از چالش‌های اصلی، وجود اشکالات در نوشتار عددی بود. در بسیاری از دستورهای آشپزی، اعداد به صورت متنی مانند "یک"، "دو"، "نصف"، "نیم" یا به شکل اعشاری فارسی مانند " $\frac{1}{2}$ " و " $\frac{1}{4}$ " نوشته شده بودند. برای مدیریت این مشکل، دیکشنری خاصی تعریف شد تا این کلمات و نمادها به مقادیر عددی معادل تبدیل شوند.

```
WORD_TO_NUMBER = {
    "نیم": 0.5,
    "نصف": 0.5,
    "ربع": 0.25,
    "یک": 1,
    "دو": 2,
    "سه": 3,
    "چهار": 4,
    "پنج": 5,
    "شش": 6,
    "هفت": 7,
    "هشت": 8,
    "نه": 9,
    "ده": 10,
    "%": 0.5,
    "%": 0.75,
    "1/2": 0.5,
    "1/4": 0.25,
    "1/3": 0.33,
}
```

عدم رعایت نیم‌فاصله‌ها و مشکلات نگارشی:

یکی دیگر از چالش‌های رایج، عدم رعایت استانداردهای نگارشی فارسی به ویژه در استفاده از نیم‌فاصله‌ها بود. مثلاً واژه‌هایی مانند «قاشق چای خوری» گاهی به صورت «قاشق چای خوری»، «قاشق چایخوری» یا حتی «ق چ خ» نوشته می‌شدند. برای مقابله با این پراکندگی، لیستی از واحدهای رایج تعریف شد تا تنوع نوشتاری به شکل استاندارد شناسایی و پردازش شود:

```
UNIT_WORDS = [
    "قاشق سوپخوری", "قاشق چایخوری", "قاشق غذاخوری", "عدد", "یمانه",
    "فنجان", "لیوان", "بشقاب", "کاسه", "قاشق مرباخوری",
    "پنس", "قاشق چای خوری", "قاشق غ", "ق چای خوری", "ق غذاخوری", "پ", "ق م", "ق ج", "ق ج", "ق ج", "ق غ", "ق غ", "حبه", "کیلو", "گرم",
    "قاشق چایخوری", "نوک", "قاشق ج", "ق مرباخوری", "قاشق غذا خوری", "استکان",
]
```

وجود توصیف‌های غیر عددی برای میزان مواد اولیه:

در بسیاری از دستورها به جای مقدار دقیق، عباراتی مانند «به میزان لازم»، «به دلخواه» یا «کمی» استفاده شده بود که باعث می‌شد استخراج مقادیر کمی دشوار شود. برای مدیریت این حالت‌ها، الگوهایی تعریف شد تا این توصیف‌ها شناسایی و به درستی ثبت شوند:

```
DESC_PATTERNS = [
    "به میزان کافی", "به میزان لازم", "به مقدار لازم",
    "به دلخواه", "بمقدار لازم", "به میزان دلخواه", "به اندازه نیاز", "بمقدار لازم", "کمی", "به مقدار دلخواه", "مقداری", "به اندازه لازم",
]
```

ناهماهنگی در نوشتار اعداد فارسی و انگلیسی:

لازم بود اعداد فارسی مانند «۲» یا «۳» به معادل انگلیسی «2» و «3» تبدیل شوند. برای این هدف، یک نگاشت نرمال‌سازی اعداد تعریف شد.

مشکلات در ترکیب عدد و متن:

گاهی اعداد و متن بدون فاصله در کنار هم نوشته شده بودند (مثلاً «۲عدد» یا «۳پیمانه»). برای جداسازی صحیح این ترکیب‌ها از الگوهای جداسازی استفاده شد.

۶- نتایج نهایی

در این بخش نمونه ای از خروجی هر بخش از روند کار و همچنین گزارش آماری بررسی می‌شود. بخش اول - استخراج اطلاعات خواسته شده از سایت:

[illegible]

بخش دوم - نتیجه لیبل گذاری:

- نمونه با تگ good:

```
{
  "title": "خمص غذای عربی خوزستان",
  "locations": [
    {
      "province": "خوزستان",
      "city": "امواز",
      "latitude": 31.3183,
      "longitude": 48.6706
    }
  ],
  "ingredients": [
    {
      "name": "برنج",
      "amount": 0.5,
      "unit": "پیمانه"
    },
    {
      "name": "آب",
      "amount": null,
      "unit": null
    },
    {
      "name": "نمک و ادویه و فلفل",
      "amount": null,
      "unit": null
    },
    {
      "name": "امتناع خردفنده",
      "amount": 1.0,
      "unit": "کیلو"
    },
    {
      "name": "لیموعماتی",
      "amount": 2.0,
      "unit": "عدد"
    },
    {
      "name": "پیازسرخ حده",
      "amount": 1.0,
      "unit": "عدد"
    }
  ],
  "instructions": [
    "امتناع روغورد کرده ومیریزیم داخل قابلمه تا کمی ازجوش کم بشه بعدیرتجی روکه از قبل خیس کرده بودیم روداخل امتناع میریزیم ومقداری آب تاحدی که برنج پزده میریزیم",
    "حدود ۲۰ دقیقه میریزیم بعدپیازوادویه مارواضافه میکنیم",
    "لیموعماتی روپایهپوست ومستشو جداکنیم وقطط میامی داخل لیمو روداخل موادمیریزیم ومخلوط میکنیم",
    "حدود اصاعت طول میکشه تا موادخوب جابجسته یعنی باید آب برنج وامتناع خوب جمع بشه ویداری دم بشه",
    "این غذا یه سبزی دیگه هم داره که اسمش توله ممد که مال خوزستان ولی با امتناع میشه پخت خیلی خوب طعمه امیدوارم خوشتون بیاد"
  ],
  "meal_type": [
    "غذای اصلی برنجی"
  ],
  "occasion": "خام",
  "images": {
    "main": "https://img-global.cpcdn.com/recipes/025fe3c6beea2f41/480x480cq70/photo.jpg",
    "step1": null,
    "step2": null
  },
  "id": 23,
  "answer2": "Good",
  "answer": "Good",
  "annotator": 1,
  "annotation_id": 92,
  "created_at": "2025-04-26T00:41:11.449512Z",
  "updated_at": "2025-04-26T00:41:11.449512Z",
  "lead_time": 288.928
},
```

- نمونه با تگ bad:

```
{
  "title": "مطبخ مرغ، غذای محلی استان خوزستان، آبادان، خرمشهر",
  "locations": [
    {
      "province": "خوزستان",
      "city": "خرمشهر",
      "latitude": 30.4396,
      "longitude": 48.1817
    }
  ],
  "ingredients": [
    {
      "name": "مرغ، میشه بران",
      "amount": null,
      "unit": null
    },
    {
      "name": "برنج به مقدار تعداد",
      "amount": null,
      "unit": null
    },
    {
      "name": "پیازمخروط",
      "amount": 4.0,
      "unit": "عدد"
    },
    {
      "name": "ادویه، کاری، دارچین فلفل ونگ",
      "amount": null,
      "unit": null
    },
    {
      "name": "مغذات میریزیم، کشمش، پیاز مکاری",
      "amount": null,
      "unit": null
    }
  ],
  "instructions": [
    "ابتدا مرغ رو تدریج به تعداد بر تدر میریزیم رو گاز و ادویه و پیاز می بریزیم فعلا فلفل، بعد که مرغ پخت و به روغن افشان میریزیم از آب مرغ جدا می کنیم و کنار میذاریم بعد مرغی که درسته داخل دیگ می بریزیم اما فلفل میریزان پخته رو میریزیم و بعد می پختیم",
    "مرغ داخل یک دیگ پیاز بزرگ رو حال می کنیم و با روغن مرغ می کنیم بکم که رنگش تغییر کرد پخت فلفل خامورد، پودر ادویه رو می ترییم و به معراذ نمک و مقدارش (تقریباً دم کرده و گلی کاری و خوب گند میبیم که بودا ادویه ما دربیاید بعد مرغ رو آب مرغ که کنار",
    "درکنار میزنیم تا لایق، ماست بازاری و سبزی و فلفل و پیازمرو کتیم",
    "سویج پختن مرغ پون نوب پخته میشه براد مرغ غن نشه کبابیه رنگه طعمی بگیره اگه بیشتر مرغ کتیم مرغ مکت میشه"
  ],
  "meal_type": [
    "غذای اصلی برنجی"
  ],
  "occasion": "خام",
  "images": {
    "main": "https://img-global.cpcdn.com/recipes/188c71d54f66646/480x480cq70/photo.jpg",
    "step1": null,
    "step2": null
  },
  "id": 20,
  "answer": "Bad",
  "answer2": "Bad",
  "annotator": 1,
  "annotation_id": 89,
  "created_at": "2025-04-26T00:35:36.988060Z",
  "updated_at": "2025-04-26T00:35:36.988060Z",
  "lead_time": 130.233
},
```

بخش سوم – اصلاح لیبل های bad:

- قبل اصلاح:

```
{
  "title": "آبادان [آ]",
  "locations": [
    {
      "province": "خوزستان",
      "city": "آبادان",
      "latitude": 30.3392,
      "longitude": 48.3043
    }
  ],
  "ingredients": [
    {
      "name": "گوشت گوسفندی",
      "amount": 500,
      "unit": "گرم"
    },
    {
      "name": "بلغور گندم",
      "amount": 1,
      "unit": "لیوان"
    },
    {
      "name": "کوردی پرتیج نکود مدس سبز و لوبیا سفید از هر کدام",
      "amount": 0.5,
      "unit": "لیوان"
    },
    {
      "name": "تره",
      "amount": 2,
      "unit": "پیمانه"
    },
    {
      "name": "دسته کوچک پیاز",
      "amount": 3,
      "unit": "عدد"
    },
    {
      "name": "متوسط نمک، فلفل قرمز و سبزه، زردچوبه به مقدار لازم گرد لیمو",
      "amount": null,
      "unit": null
    }
  ],
  "instructions": [
    "گوشت را با پیاز جداگانه بپزید.",
    "حبوبات را نیز کاملاً بپزید. بعد از پخت، پرتیج و بلغور را اضافه کنید.",
    "پرتیج و بلغور باید تا حدی پخته شوند که کاملاً له شده باشند (تقریباً مانند هله زرد).",
    "لیمو زردچوبه و فلفل را با پیاز و گوشت اضافه کنید.",
    "دقیقه بعد، تره را نیز که خرد کرده اید اضافه کنید 10",
    "در این مرحله گوشت پخته را با گوشت کوب بکوبید و به این مواد اضافه کنید.",
    "(باید تقریباً زیاد باشد [آ] را هم بزنید زیرا زود ته میگیرد) (نمک زیر [آ] باید دقت داشته باشید که مرتباً",
    "زمانی حرارت را کم کنید که تره ها و نمک را اضافه کرده باشید یعنی تقریباً مرحله آخر (بعد از پخت کامل پرتیج و بلغور)",
    "پخته. هم بزنید [آ] دقیقه بعد از اضافه کردن تره ها و نمک پیازها را خلال و سرخ کرده، گرد لیمو امالی را به آن اضافه کنید و در 40",
    "آماده سرو می باشد [آ] دقیقه بعد 10."
  ],
  "meal_type": [
    "و سوپ [آ]"
  ],
  "occasion": "خام",
  "images": {
    "main": null,
    "steps": []
  },
  "id": 32,
  "answer": "Bad",
  "answer2": "Bad",
  "annotator": 1,
  "annotation_id": 101,
  "created_at": "2025-04-26T00:50:25.364413Z",
  "updated_at": "2025-04-26T00:50:25.364413Z",
  "load_time": 227.193
},
```

- بعد اصلاح:


```
{
  "title": "آبادان آش",
  "locations": [
    {
      "province": "خوزستان",
      "city": "آبادان",
      "latitude": 30.3392,
      "longitude": 48.3043
    }
  ],
  "ingredients": [
    {
      "name": "گوشت گوسفندی",
      "amount": 500,
      "unit": "گرم"
    },
    {
      "name": "بلغور گندم",
      "amount": 1,
      "unit": "لیوان"
    },
    {
      "name": "برنج نخود عدس سبز و لوبیا سفید از هر کدام",
      "amount": 0.5,
      "unit": "لیوان"
    },
    {
      "name": "تره",
      "amount": 2,
      "unit": "پیمانه"
    },
    {
      "name": "پیازچه",
      "amount": 3,
      "unit": "دسته"
    },
    {
      "name": "نمک، فلفل قرمز و سبب، زردچوبه، گرد لیمو",
      "amount": "به مقدار لازم",
      "unit": null
    }
  ],
  "instructions": [
    "گوشت را با پیاز جداگانه بپزید.",
    "حبوبات را نیز کاملاً بپزید. بعد از پخت، برنج و بلغور را اضافه کنید.",
    "برنج و بلغور باید تا حدی پخته شوند که کاملاً له شده باشند(تقریباً مانند حله زرد).",
    "سبب زردچوبه و فلفل ها را اضافه نمایید.",
    "دقیقه بعد، تره ها را نیز که خرد کرده اید اضافه کنید 10",
    "در این مرحله گوشت پخته را با گوشت کوب بکوبید و به این مواد اضافه کنید.",
    "(باید تقریباً زیاد باشد آش) را هم بزنید زیرا زود ته میگیرد(قلعه زیر آش باید دقت داشته باشید که مرتباً",
    "زمانی حرارت را کم کنید که تره ها و نمک را اضافه کرده باشید یعنی تقریباً مرحله آخر(بعد از پخت کامل برنج و بلغور)",
    "روخته. هم بزنید آش دقیقه بعد از اضافه کردن تره ها و نمک پیازها را خلال و سرخ کرده، گرد لیمو امالی را به آن اضافه کنید و در 40",
    "آماده سرو می باشد آش دقیقه بعد 10."
  ],
  "meal_type": [
    "و سوپ آش"
  ],
  "occasion": "خام",
  "images": {
    "main": null,
    "steps": []
  },
  "id": 32,
  "answer": "Good",
  "annotator": 1,
  "annotation_id": 101,
  "created_at": "2025-04-26T00:50:25.364413Z",
  "updated_at": "2025-04-26T00:50:25.364413Z",
  "lead_time": 227.193
},
```

بخش چهارم – گزارش آماری:

در ادامه فاز اول پروژه، با استفاده از ابزارهای آماری و پردازش زبان طبیعی فارسی، به تحلیل محتوای متنی دستورات غذایی پرداختیم. هدف این مرحله شناسایی ویژگی‌های آماری، الگوهای زبانی رایج و ساخت مصورسازی‌هایی بود که به فهم بهتر داده‌های متنی کمک کنند.

مراحل انجام کار:

۱- نصب ابزارهای موردنیاز

برای شروع فرآیند تحلیل متون، ابتدا ابزارهای تخصصی برای پردازش زبان طبیعی فارسی نصب شدند. در این پروژه از کتابخانه‌های معروف و قدرتمند **Hazm** و **DadmaTools** استفاده شد. **Hazm** برای کارهای پایه‌ی پردازش زبان فارسی و **DadmaTools** برای تحلیل‌های پیشرفته‌تر، مانند Named Entity Recognition یا POS Tagging، کاربرد دارد. نصب این ابزارها با استفاده از دستور `pip install` در محیط Python انجام شد.

```
!pip install hazm
!pip install dadmatools
```

۲- نرمال‌سازی، پیش‌پردازش و tokenize کردن

در این مرحله، متون خام شامل دستورات پخت غذاها پاک‌سازی شدند. نرمال‌سازی شامل حذف فاصله‌های اضافی، علائم نگارشی نامناسب، و یکدست‌سازی کلمات (مثلاً تبدیل "می‌شود" به "می‌شود") بود. سپس با استفاده از **Stemming**، کلمات به ریشه‌ی خود تبدیل شدند (مثلاً "پختن"، "پخته"، "می‌پزد" همگی به "پخت"). همچنین کلمات پرتکرار و بی‌اهمیت (**Stop Words**) مانند "از"، "را"، "و" حذف شدند تا تحلیل دقیق‌تری صورت گیرد.

نمونه قبل از اعمال نرمال‌سازی، پیش‌پردازش و tokenize کردن

(اگر داخل زودپز بگذارید، زودتر می‌پزد و گرنه در حالت معمولی ۳ الی ۴ ساعت برای پخت، زمان میبرد) \r\n، ابتدا باقالی را با پوست میگذاریم بپزد

نمونه بعد از اعمال نرمال‌سازی، پیش‌پردازش و tokenize کردن

```
[
    "ابتدا",
    "باقالی",
    "را",
    "با",
    "پوست",
    "میگذاریم",
    "بپزد",
    ",",
    "(",
    "اگر",
    "داخل",
    "زودپز",
    "بگذارید",
    ",",
    "زودتر",
    "می",
    "پزد",
    "و",
    "گرنه",
    "در",
    "حالت",
    "معمولی",
    "3",
    "الی",
    "4",
    "ساعت",
    "برای",
    "پخت",
    ",",
    "زمان",
    "میبرد",
    ")"
```

۳- آمار کلی داده‌های متنی

برای تحلیل بهتر متون دستور پخت، ابتدا آمار اولیه‌ای از مجموعه داده‌ها استخراج شد که شامل تعداد رکوردها (تعداد دستورهای پخت) و جزئیات رکوردهای مربوط به هر استان (اعم از تعداد انواع وعده‌های غذایی مربوط به هر استان و موقعیت مربوط به هر غذا)، تعداد کل کلمات در مجموعه، و میانگین طول رشته‌های متنی بود. این آمار به درک بهتر حجم داده و آماده‌سازی آن برای پردازش‌های بعدی کمک می‌کند.

خلاصه‌ی نتایج آماری و نموداری:

- جزئیات رکوردهای مربوط به هر استان (اعم از تعداد انواع وعده‌های غذایی مربوط به هر استان و موقعیت مربوط به هر غذا)

استان همدان:

Hamedan:		
Number of recipes: 31		
Types of meal:		
	Type	amount
0	غذای اصلی گوشتی	8
1	آش و سوپ	11
2	دسر	6
3	نان و شیرینی	4
4	پیش غذا و مکمل	1
5	غذای اصلی برنجی	1
Occasions:		
	Occasion	amount
0	شام	19
1	عصرانه	11
2	ناهار	1

استان ایلام:

Ilam:

Number of recipes: 25

Types of meal:

Type	amount
0 غذای اصلی گیاهی	7
1 غذای اصلی گوشتی	7
2 غذای اصلی برنجی	4
3 آش و سوپ	3
4 دسر	3
5 نان و شیرینی	1

Occasions:

Occasion	amount
0 شام	13
1 ناهار	7
2 صبحانه	1
3 عصرانه	4

استان کرمانشاه:

Kermanshah:

Number of recipes: 33

Types of meal:

Type	amount
0 غذای اصلی گوشتی	12
1 آش و سوپ	6
2 غذای اصلی برنجی	4
3 دسر	5
4 نان و شیرینی	5
5 پیش غذا و مکمل	1

Occasions:

Occasion	amount
0 شام	18
1 ناهار	5
2 عصرانه	10

استان خوزستان:

Khoozestan:		
Number of recipes: 44		
Types of meal:		
	Type	amount
0	غذای اصلی گوشتی	5
1	غذای اصلی برنجی	9
2	غذای اصلی گیاهی	5
3	پیش غذا و مکمل	2
4	غذای اصلی دریایی	4
5	آش و سوپ	7
6	نان و شیرینی	4
7	دسر	8
Occasions:		
	Occasion	amount
0	شام	23
1	ناهار	9
2	عصرانه	9
3	دسر	1
4	مناسب برای کنار غذا	1
5	صبحانه	1

استان لرستان:

Lorestan:		
Number of recipes: 30		
Types of meal:		
	Type	amount
0	غذای اصلی برنجی	2
1	آش و سوپ	7
2	غذای اصلی گوشتی	8
3	غذای اصلی	3
4	دسر	3
5	نان و شیرینی	4
6	پیش غذا و مکمل	2
7	غذای اصلی گیاهی	1
Occasions:		
	Occasion	amount
0	ناهار	11
1	شام	12
2	عصرانه	7

استان مرکزی:

Markazi:

Number of recipes: 36

Types of meal:

	Type	amount
0	غذای اصلی گوشتی	8
1	آش و سوپ	12
2	غذای اصلی گیاهی	2
3	غذای اصلی برنجی	1
4	پیش غذا و مکمل	1
5	نان و شیرینی	5
6	دسر	6
7	صبحانه	1
8	افطاری	1

Occasions:

	Occasion	amount
0	شام	15
1	ناهار	10
2	عصرانه	5
3	ماه رمضان	3
4	عید نوروز	3

- تعداد کل کلمات داخل دیتاست (شامل کلمات داخل URL ها و حتی کلمات کلیدها و Null ها و None ها، منهای اعداد):

↔ Number of Words in the whole dataset (including URLs and Keys and Null or None values): 49084

- میانگین طول جملات داخل دستورات غذایی در همه ی استان ها:

↔ Mean of Sentence Lengths in all 6 Provinces is: 44

در جهت خوانایی بیشتر نمودارها و جداول خواشمندیم فایل نوت NLP_Project_Statistical_Analysis مراجعه کنید. در بخش اول برای هر استان تعداد هر meal type و occation ای محاسبه شده است. برای مثال استان همدان را در تصویر مشاهده می‌کنید.

برای مشاهده بقیه استان‌ها لطفاً به نوت بوک مراجعه کنید.

کدها و فایل‌های اجرایی مرتبط با این پروژه از طریق مخزن گیت‌هاب در دسترس هستند.